

HAERYONG HIGH SCHOOL, ROADMAP TO SAC: NN
FOUNDATIONS, REINFORCEMENT LEARNING; NOT AN OFFICIAL
CLASS

1. RL MDP



Instructors: Joun Won

Joun Won

2026 Spring

Contents

1	RL MDP	3
1.1	강화학습을 쓰는 이유	3
1.2	RL이란 무엇인가	3
1.3	RL, 지도학습, 비지도학습의 차이	4
1.4	강화학습의 구성 요소	5
1.5	마르코프 결정 과정 (Markov Decision Process, MDP)	6
1.5.1	동기	6
1.5.2	마르코프 성질	6
1.5.3	MDP의 형식적 정의	7
1.5.4	할인율과 리턴의 수렴	8
1.5.5	궤적과 에피소드	8
1.5.6	MDP 하에서의 가치 함수	9
1.5.7	예제: 간단한 MDP	9
1.5.8	요약	10

1 RL MDP

1.1 강화학습을 쓰는 이유

왜 강화학습(RL)을 사용할까?

- 정확한 시스템 모델을 알 수 없거나 만들기 어려울 때.
- 비선형성 + 고차원 시스템.
- 모델 불일치(model mismatch)에 대한 강건성.
- 명시적으로 정의하기 어려운 성능 지표를 최적화할 때.
- 온라인 적응(adaptive control)과의 유사성.

1.2 RL이란 무엇인가

강화학습(Reinforcement Learning): 인공지능 프로그램이 다양한 행동을 시도해보고 그 결과를 관찰함으로써 의사결정을 학습하는 머신러닝의 한 종류.

강화학습에서 자율 에이전트(autonomous agent)는 인간 사용자의 어떠한 지침도 없이 시행착오(trial and error)를 통해 과업을 수행하는 법을 학습한다.




Figure 1.1: 강화학습에서 에이전트-환경 상호작용 루프. 각 타임스텝 t 마다 에이전트는 상태 S_t 와 보상 R_t 를 관측하고, 행동 A_t 를 취하며, 환경은 새로운 상태 S_{t+1} 과 보상 R_{t+1} 로 전이한다.

1.3 RL, 지도학습, 비지도학습의 차이

머신러닝 패러다임은 일반적으로 세 가지 큰 범주로 나뉘며, 이는 주로 학습 알고리즘이 데이터나 환경으로부터 어떤 종류의 피드백을 받는지에 따라 구분된다.

지도학습(Supervised Learning). 지도학습에서는 알고리즘에 라벨이 달린 예제들의 데이터셋 $\{(x_i, y_i)\}_{i=1}^N$ 이 주어지는데, 여기서 x_i 는 입력이고 y_i 는 그에 대응하는 “정답”(라벨)이다. 목표는 보지 못한 입력에도 잘 일반화되는 매핑 $f: X \rightarrow Y$ 를 학습하는 것이다. 피드백은 교시적(*instructive*)이다: 모든 입력에 대해, 모델이 실제로 무엇을 예측했든 상관없이 정답이 정확히 무엇이었는지가 알려진다.

- **피드백 유형:** 모든 예제에 대해 정답 라벨이 제공됨.
- **목표:** 예측 오차 최소화 (예: 분류 오차, 회귀 손실).
- **예시:** 이미지 분류, 스팸 탐지, 주택 가격 예측.

비지도학습(Unsupervised Learning). 비지도학습에서는 알고리즘에 입력 $\{x_i\}_{i=1}^N$ 만 주어지고 라벨은 전혀 없다. 목표는 특정 출력을 예측하는 것이 아니라, 데이터 자체 내에 숨겨진 구조, 패턴, 또는 그룹을 발견하는 것이다.

- **피드백 유형:** 없음 — 라벨도 보상도 제공되지 않음.
- **목표:** 구조 발견 (예: 군집, 잠재 요인, 밀도 추정).
- **예시:** 군집화(k-means), 차원 축소(PCA), 이상 탐지.

강화학습(Reinforcement Learning). 강화학습(RL)에서는 에이전트가 일련의 타임스텝에 걸쳐 환경과 상호작용한다. 각 타임스텝 t 마다 에이전트는 상태 S_t 를 관측하고, 행동 A_t 를 취하며, 다음 상태 S_{t+1} 과 함께 스칼라 보상 R_{t+1} 을 받는다(그림 1.1 참고). 에이전트에게는 어떤 행동이 “정답”인지 결코 알려주지 않는다; 에이전트는 보상 신호를 교시적 피드백이 아닌 평가적(*evaluative*) 피드백으로 활용하여 시행착오를 통해 좋은 행동을 스스로 발견해야 한다.

- **피드백 유형:** 종종 지연되는 스칼라 보상 신호로, 행동이 얼마나 좋았는지를 나타낼 뿐 — 정답 행동이 무엇이었는지는 알려주지 않음.
- **목표:** 시간에 따른 누적(기대 할인) 보상을 최대화하는 정책 $\pi(a | s)$ 를 학습하는 것.
- **예시:** 게임 플레이(알파고, 아타리), 로봇 제어, 자원 할당.

핵심 구분: 평가적 피드백 vs. 교시적 피드백. RL과 지도학습의 근본적 차이는 피드백의 성격에 있다:

- 지도학습: 교시적 피드백 — 라벨이 모델에게 무엇을 출력했어야 하는지 직접 알려준다.
- 강화학습: 평가적 피드백 — 보상은 에이전트에게 그 행동이 얼마나 좋았는지는 알려주지만, 최선의 행동이 무엇이었는지는 알려주지 않는다. 에이전트는 더 나은 행동을 찾기 위해 능동적으로 탐색(explore)해야 한다.

또한 RL 문제는 본질적으로 순차적(*sequential*)이다: 지금 취한 행동이 미래의 상태와 미래의 보상에 영향을 줄 수 있다(지연된 보상 / credit assignment 문제). 반면 지도학습과 비지도학습은 일반적으로 각 데이터 포인트를 독립동일분포(i.i.d.)로 취급한다.

	지도학습	비지도학습	강화학습
데이터	라벨링된 (x_i, y_i)	라벨 없는 x_i	순차적 (S_t, A_t, R_t)
피드백	정답 라벨(교시적)	없음	스칼라 보상(평가적)
피드백 시점	각 예제마다 즉시	—	종종 지연됨
목표	예측 오차 최소화	구조 발견	누적 보상 최대화
데이터 가정	i.i.d. 샘플	i.i.d. 샘플	순차적, non-i.i.d. (에이전트 자신의 행동에 의존)
탐색 필요 여부?	아니오	아니오	예

Table 1.1: 지도학습, 비지도학습, 강화학습의 비교.

1.4 강화학습의 구성 요소

Definition 1. 상태 (S_t): 시간 t 에서의 환경에 대한 표현으로, 에이전트가 다음 행동을 결정하는 데 사용한다. 환경의 전체 상태(완전 관측 가능)일 수도 있고, 부분 관측(부분 관측 가능)일 수도 있다.

Definition 2. 행동 (A_t): 시간 t 에서 에이전트가 가능한 행동 집합 $\mathcal{A}$ (또는 행동 집합이 현재 상태에 의존하는 경우 $\mathcal{A}(S_t)$)로부터 내리는 선택으로, 환경에 영향을 미치고 다음 상태로의 전이를 결정한다.

Definition 3. 보상 (R_t): 행동을 취한 후 환경으로부터 받는 스칼라 피드백 신호 $R_t \in \mathbb{R}$ 로, 그 타임스텝에서의 행동이 얼마나 좋았거나 나빴는지를 나타낸다. 에이전트의 목표는 즉각적인 보상만이 아니라 시간에 따른 누적 보상을 최대화하는 것이다.

Definition 4. 정책 (π): 상태에서 행동으로의 매핑으로, 에이전트의 행동 방식을 정의한다. 결정론적($\pi(s) = a$)일 수도 있고, 확률적($\pi(a | s) = P(A_t = a | S_t = s)$)일 수도 있다.

Definition 5. 모델 (Model): 환경의 동역학에 대한 에이전트의 (선택적인) 표현으로, 다음 상태를 예측하는 전이 함수 $P(s' | s, a)$ 와 기대 보상을 예측하는 보상 함수 $R(s, a)$ 로

구성된다. 모델을 사용하는 에이전트를 *model-based*라 하고, 사용하지 않는 에이전트를 *model-free*라 한다.

Definition 6. 환경 (Environment): 에이전트가 상호작용하는, 에이전트 외부의 모든 것. 환경은 에이전트의 행동 A_t 를 받아 새로운 상태 S_{t+1} 로 전이하고 보상 R_{t+1} 을 내보낸다 (그림 1.1 참고).

Definition 7. 에이전트 (Agent): 상태를 관측하고, 자신의 정책에 따라 행동을 선택하며, 받은 보상을 바탕으로 정책(및/또는 가치 함수나 모델)을 업데이트하는 학습자이자 의사결정자로, 목표는 누적 보상을 최대화하는 것이다.

1.5 마르코프 결정 과정 (Markov Decision Process, MDP)

1.5.1 동기

지금까지 우리는 강화학습의 구성 요소인 상태, 행동, 보상, 정책, 리턴, 가치 함수를 비형식적으로 소개하였다. 마르코프 결정 과정(MDP)은 이 모든 구성 요소를 하나의 잘 정의된 구조로 형식화하는 수학적 프레임워크이다. 거의 모든 RL 문제는 MDP(혹은 그 일반화)로 형식화될 수 있으며, 이 때문에 MDP는 불확실성 하의 순차적 의사결정의 기본 모델로 여겨진다.

1.5.2 마르코프 성질

Definition 8. 마르코프 성질 (Markov Property): 상태 S_t 가 다음을 만족하면 마르코프 (Markov)하다고 한다:

$$P(S_{t+1} | S_t) = P(S_{t+1} | S_1, S_2, \dots, S_t).$$

즉, 현재 상태가 주어지면 미래는 과거와 조건부 독립이다.

직관적으로, 현재 상태는 미래를 예측하는 데 관련된 과거의 모든 정보를 담고 있다. 이를 흔히 무기억성 (memoryless property)이라 부른다.

Lemma 1.1: 마르코프 성질 하의 궤적 분해

수열 $S_0, S_1, \dots, S_T$ 의 모든 상태 S_t 가 마르코프 성질을 만족한다면, 궤적의 결합 확률은 다음과 같이 분해된다:

$$P(S_0, S_1, \dots, S_T) = P(S_0) \prod_{t=0}^{T-1} P(S_{t+1} | S_t).$$

Proof 1.1: 마르코프 성질 하의 꺾적 분해

확률의 연쇄 법칙(chain rule)에 의해, 임의의 확률변수 수열에 대해

$$P(S_0, S_1, \dots, S_T) = P(S_0) \prod_{t=0}^{T-1} P(S_{t+1} | S_0, S_1, \dots, S_t).$$

마르코프 성질(정의 8)에 의해, 각 조건부 항은 다음을 만족한다:

$$P(S_{t+1} | S_0, \dots, S_t) = P(S_{t+1} | S_t).$$

이를 위의 연쇄 법칙 식에 대입하면

$$P(S_0, S_1, \dots, S_T) = P(S_0) \prod_{t=0}^{T-1} P(S_{t+1} | S_t),$$

가 되어 주장이 성립한다. ■

□

Remark. 이 보조정리(Lemma)는 마르코프 성질이 계산적으로 왜 그렇게 강력한지를 보여준다: 전체 히스토리에 대해 지수적으로 커지는 결합 분포를 저장할 필요 없이, 1-스텝 전이 확률 $P(S_{t+1} | S_t)$ 만 있으면 충분하다.

행동과 보상을 포함하도록 확장하면, 마르코프 성질은 다음과 같이 된다:

$$P(S_{t+1}, R_{t+1} | S_t, A_t) = P(S_{t+1}, R_{t+1} | S_1, A_1, R_1, \dots, S_t, A_t),$$

이것이 MDP 프레임워크의 핵심 가정이다.

1.5.3 MDP의 형식적 정의

Definition 9. 마르코프 결정 과정: MDP는 다음 5-튜플로 정의된다:

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$$

여기서 $\mathcal{S}$ 는 상태 공간, $\mathcal{A}$ 는 행동 공간, $P(s' | s, a)$ 는 상태 전이 확률 함수, $R(s, a) = \mathbb{E}[R_{t+1} | S_t = s, A_t = a]$ 는 보상 함수, $\gamma \in [0, 1]$ 은 할인율(discount factor)이다.

각 구성 요소의 해석.

- $\mathcal{S}, \mathcal{A}$: 무엇이 가능한가.
- P : 세계가 어떻게 변화하는가 (환경의 동역학).
- R : 무엇이 바람직한가 (목표).
- γ : 에이전트가 미래를 얼마나 중요하게 여기는가.

1.5.4 할인율과 리턴의 수렴

Definition 10. 리턴 (*Return*): $G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$.

자연스러운 질문은, 무한 호라이즌을 가진 지속적 과업(continuing task)에서 G_t 가 잘 정의되는지(유한한지) 여부이다. 다음 정리가 이에 답한다.

Theorem 1.2: 할인된 리턴의 유계성

보상이 유계, 즉 모든 t 에 대해 $|R_t| \leq R_{\max}$ 이고 $\gamma \in [0, 1)$ 라 하자. 그러면 할인된 리턴 G_t 는 유한하며 다음을 만족한다:

$$|G_t| \leq \frac{R_{\max}}{1 - \gamma}.$$

Proof 1.2: 할인된 리턴의 유계성

삼각부등식과 보상의 유계성에 의해,

$$|G_t| = \left| \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \right| \leq \sum_{k=0}^{\infty} \gamma^k |R_{t+k+1}| \leq \sum_{k=0}^{\infty} \gamma^k R_{\max} = R_{\max} \sum_{k=0}^{\infty} \gamma^k.$$

$0 \leq \gamma < 1$ 이므로, 등비급수는 수렴한다:

$$\sum_{k=0}^{\infty} \gamma^k = \frac{1}{1 - \gamma}.$$

따라서

$$|G_t| \leq \frac{R_{\max}}{1 - \gamma},$$

이며 이는 유한하다. ■

□

Remark. 바로 이 때문에 지속적 과업(continuing task)에서는 $\gamma < 1$ 이 필요하다: 할인이 없다면 유계이지만 0이 아닌 보상의 무한합은 발산한다. 에피소딕 과업(episodic task)의 경우, 종료 상태에서 합이 자동으로 유한해지므로 $\gamma = 1$ 이 허용되기도 한다.

1.5.5 궤적과 에피소드

Definition 11. 에피소딕 과업 (*Episodic Task*): 각각 종료 상태(terminal state)로 끝나는 유한한 에피소드들로 나뉘는 과업.

Definition 12. 지속적 과업 (*Continuing Task*): 자연스러운 종료 지점이 없는 과업; 상호 작용이 무한히 계속된다.

1.5.6 MDP 하에서의 가치 함수

Definition 13. 상태-가치 함수 (*State-Value Function*): $V_\pi(s) = \mathbb{E}_\pi [G_t \mid S_t = s]$.

Definition 14. 행동-가치 함수 (*Action-Value Function*): $Q_\pi(s, a) = \mathbb{E}_\pi [G_t \mid S_t = s, A_t = a]$.

두 가치 함수는 서로 독립적이지 않다; 다음 정리가 그 관계를 정확히 보여준다.

Theorem 1.3: V_π 와 Q_π 의 관계

임의의 정책 π 와 임의의 상태 $s \in \mathcal{S}$ 에 대해,

$$V_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) Q_\pi(s, a).$$

Proof 1.3: V_π 와 Q_π 의 관계

정의 13와 전체 기댓값의 법칙 (law of total expectation) 에 의해, 시간 t 에서 취한 행동에 대해 조건화하면,

$$V_\pi(s) = \mathbb{E}_\pi [G_t \mid S_t = s] = \sum_{a \in \mathcal{A}} P(A_t = a \mid S_t = s) \mathbb{E}_\pi [G_t \mid S_t = s, A_t = a].$$

정책의 정의에 의해 $P(A_t = a \mid S_t = s) = \pi(a \mid s)$ 이고, 정의 14에 의해 $\mathbb{E}_\pi [G_t \mid S_t = s, A_t = a] = Q_\pi(s, a)$ 이다. 이를 대입하면

$$V_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) Q_\pi(s, a),$$

가 되어 주장이 성립한다. ■

□

RL의 목표, 재서술. 에이전트는 다음을 만족하는 최적 정책을 찾고자 한다:

$$\pi^* = \arg \max_{\pi} V_\pi(s), \quad \forall s \in \mathcal{S}.$$

1.5.7 예제: 간단한 MDP

세 상태 $\mathcal{S} = \{\text{Cool, Warm, Overheated}\}$ 와 두 행동 $\mathcal{A} = \{\text{Slow, Fast}\}$ 를 생각해보자:

- **Cool**에서: *Slow* → Cool 유지 (보상 +1); *Fast* → Warm 또는 Cool (보상 +2, 각각 확률 0.5).
- **Warm**에서: *Slow* → Cool 또는 Warm (보상 +1, 각각 확률 0.5); *Fast* → Overheated (보상 -10).
- **Overheated**에서: 흡수 상태(absorbing), 보상 0.

*Fast*를 선택하면 즉각적인 보상은 더 크지만 파국적인 전이의 위험이 있다. *Fast*와 *Slow* 중 어느 것이 더 나은지 평가하려면 장기적 결과에 대한 추론이 필요하다 — 이는 정확히 정리 1.3과 벨만 방정식(다음 절)이 체계적으로 계산할 수 있게 해주는 부분이다.

1.5.8 요약

- 마르코프 성질(정의 8)은 궤적이 분해되도록 해주어(보조정리 1.1), 전체 히스토리를 추적할 필요를 없애준다.
- MDP(정의 9)는 환경의 동역학과 에이전트의 목표를 형식화한다.
- $\gamma < 1$ 인 할인(discounting)은 유한한 리턴을 보장한다(정리 1.2).
- V_π 와 Q_π 는 간단한 가중합으로 관계지어진다(정리 1.3).
- V_π, Q_π 를 정의로부터 직접 계산하는 것은 일반적으로 다루기 어렵다 — 이것이 다음에 다룰 벨만 방정식의 필요성을 뒷받침한다.

Instructor: Joun Won